Analyse computationnelle de l'évolution du discours politique : une cartographie sémantique des législatives de 1981 et 1988

Siméon Tsang
ENSAE
simeon.tsang@ensae.fr

Abstract

Cette étude propose une analyse automatisée de plus de 8 000 manifestes politiques issus des élections législatives françaises de 1981 et 1988. En mobilisant des techniques de Traitement du Langage Naturel (NLP), notamment BERTopic et UMAP, nous cartographions les positionnements idéologiques et thématiques des candidats. L'objectif est de mesurer l'évolution des positions politiques des partis.

1 Introduction

Dans cette étude, nous cherchons à comprendre les positionnements des candidats aux élections législatives afin de mesurer l'évolution de leur discours au cours des dernières décennies. Cependant, cette étude sur les élections de 1981 et 1988 ne représente pas moins de 8 000 manifestes politiques, ce qui les rend impossibles à analyser par un humain.

Nous allons donc contourner ce facteur limitant en utilisant des techniques de *Natural Language Processing* (NLP). Nous cherchons ainsi à étudier le positionnement des différents partis politiques sur les thèmes présents dans les deux campagnes électorales : *Comment les thématiques prioritaires et les positionnements idéologiques des partis politiques français ont-ils évolué entre les élections législatives de 1981 et 1988 ?*

2 Présentation des données et statistiques descriptives

Tout d'abord, nous utilisons les manifestes électoraux des élections législatives de 1981 et 1988 issus de la base d'archives **ARCHELEC** regroupée et maintenue par Sciences Po. En particulier, nous utilisons les transcriptions des manifestes qui se trouvent sur le Lien Gitlab et le fichier CSV contenant les métadonnées.

La transcription est un fichier texte (`.txt`) qui contient le texte du manifeste (une image initialement) et plus précisément les différents points du programme du candidat en question. Le CSV contenant les métadonnées (`meta_data`) est quant à lui composé d'un lien vers le texte, du nom du candidat, de sa profession, de son appartenance politique, etc.

Nous avons produit les analyses suivantes :
- Histogramme des partis politiques.
- Analyse en *Bag of Words* (Sac de mots).
- Mots les plus cités par parti politique.
- Longueur moyenne des textes en fonction du parti.

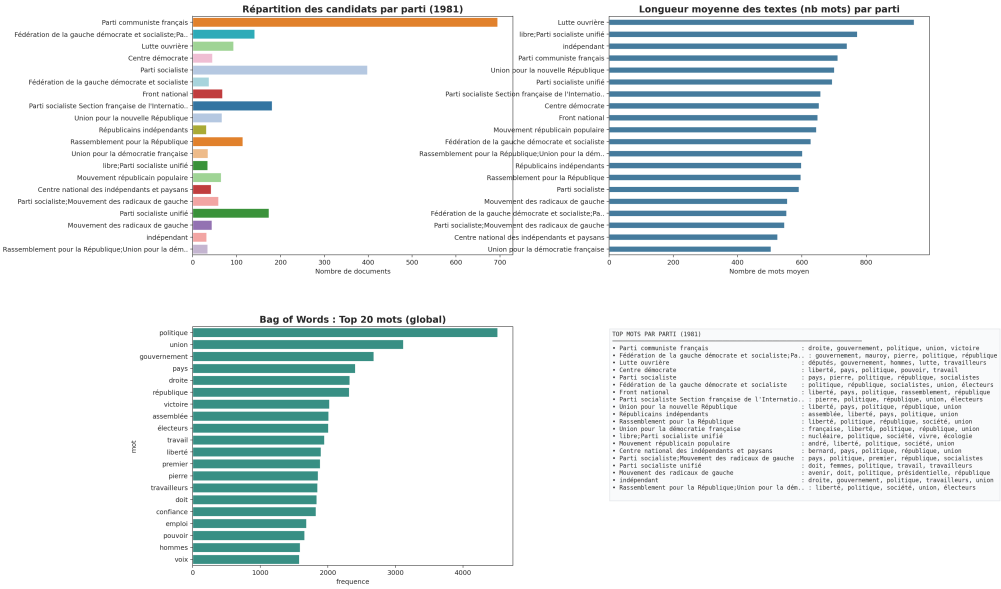

FIGURE 1 – Statistiques descriptives pour l'année 1981

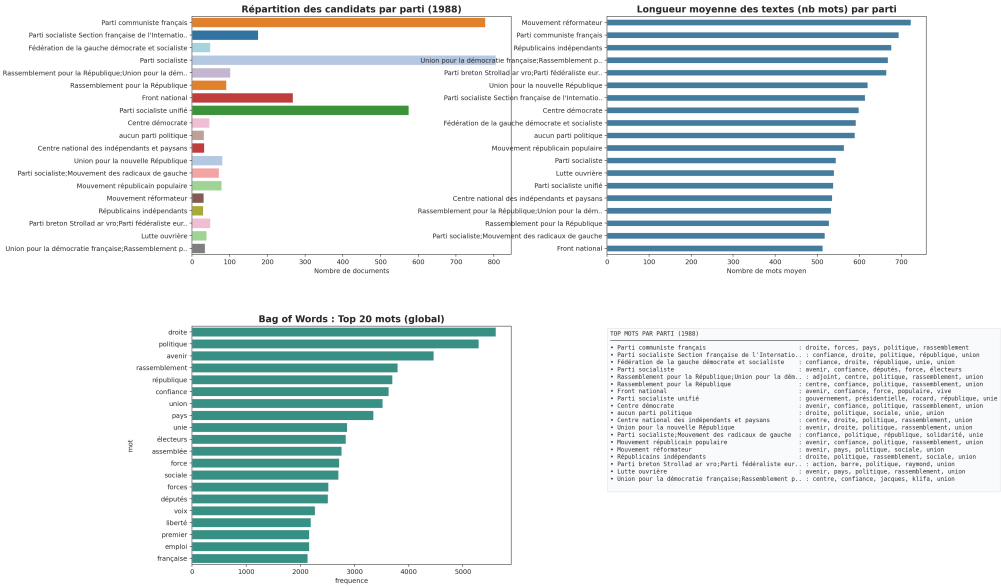

FIGURE 2 – Statistiques descriptives pour l'année 1988

Ces différents graphiques nous permettent de bien comprendre le paysage politique français de ces années-là. Nous remarquons tout d'abord qu'il existe beaucoup de petits partis, dans le sens où il y a peu de candidats affiliés à ces partis dans nos données. Malheureusement, beaucoup de candidats n'ont pas de parti mentionné dans les métadonnées ; nous ne gardons alors que ceux dont le parti est renseigné.

La longueur des textes en nombre de mots est assez homogène dans nos données. Nous remarquons toutefois que les manifestes sont globalement plus courts pour les élections de 1988 que pour celles de 1981. En 1981, Lutte ouvrière et les candidats indépendants produisent des professions de foi plus

longues (plus de 800 mots en moyenne), alors que la plupart des partis ont des manifestes d'environ 600 mots. En 1988, le Mouvement réformateur a les textes les plus longs en moyenne, suivi par le PCF.

En 1981, le PCF présente le plus grand nombre de candidats, tandis qu'en 1988, c'est le Parti socialiste qui présente le plus grand nombre de candidats. Une fragmentation du paysage politique est visible, de nombreux partis ne présentant que quelques dizaines de candidats.

L'analyse de la fréquence de mots montre une évolution lexicale entre les deux scrutins, marquant le passage d'une rhétorique d'union de la gauche en 1981 (politique, union) à une logique de compétition et de mobilisation pour l'avenir en 1988 (droite, avenir, rassemblement). De plus, les spécificités partisanes sont plus prononcées : le PCF n'utilise plus le vocabulaire de la lutte des classes pour se concentrer sur les forces politiques et la droite, tandis que le RPR maintient une identité stable ancrée dans les valeurs républicaines et la force du rassemblement.

3 État de l'art

BERTopic représente une avancée significative en combinant des plongements de phrases (embeddings) pré-entraînés (SBERT), un algorithme de partitionnement fondé sur la densité (HDBSCAN) et une version de TF-IDF par classe pour la caractérisation des thèmes. BERTopic capture le sens contextuel des termes, ce qui lui permet de distinguer des sujets thématiquement proches mais lexicalement distincts.

3.1 Réduction de dimensionnalité pour la visualisation

Projeter des représentations de haute dimension dans un espace en 2D est primordial pour la visualisation de corpus textuels. UMAP (Uniform Manifold Approximation and Projection) offre une alternative rapide et stable qui préserve mieux la structure globale du nuage de points, tout en maintenant une bonne résolution des structures locales. UMAP est une méthode de référence pour visualiser les plongements de texte. Le paramètre `n_neighbors` contrôle le compromis entre structure locale et globale ; nous utilisons `n_neighbors=15` avec une métrique cosinus, laquelle est particulièrement adaptée à la similarité textuelle.

3.2 Application à l'analyse du discours politique

L'application du Traitement du Langage Naturel (NLP) à l'analyse de corpus électoraux est un domaine en pleine expansion. L'étude fournit un cadre général pour l'analyse automatisée de textes politiques. Les travaux de [11] appliquent des modèles d'espace vectoriel pour mesurer le positionnement idéologique à partir des débats parlementaires.

4 Méthodologie

Après avoir réalisé les statistiques descriptives des données, nous avons créé une liste de *stopwords* supplémentaires afin d'obtenir des thèmes parlants et précis. Nous avons utilisé le modèle **BERTopic** pour l'extraction thématique, **HDBSCAN** pour le clustering des thèmes et l'algorithme **UMAP** pour réaliser la projection des résultats en deux dimensions afin de les visualiser.

Nous utilisons le modèle `paraphrase-multilingual-MiniLM-L12-v2` de Sentence-Transformers. Ce choix est motivé par deux raisons : (1) sa nature multilingue permet de traiter les professions de foi alsaciennes partiellement rédigées en allemand ; (2) sa taille compacte (12 couches, 384 dimensions) offre un bon compromis entre qualité sémantique et coût de calcul pour un corpus de plusieurs milliers de documents.

Nous appliquons l'algorithme UMAP aux plongements SBERT (384 dimensions) avec les paramètres suivants : `n_neighbors=15`, `min_dist=0.1`, `metric='cosine'`, `random_state=42`. La métrique cosinus est préférée à la distance euclidienne car les plongements SBERT sont des vecteurs normalisés pour lesquels la similitude cosinus est plus informative.

Pour choisir le nombre de topics que le modèle BERTopic doit conserver, nous utilisons le score de cohérence. Pour cela, nous essayons différentes valeurs de topics à conserver, puis nous calculons le

score de cohérence et nous gardons le nombre de topics avec le score le plus élevé ; cela nous donne 7 topics pour les élections législatives de 1981 et 9 pour 1988.

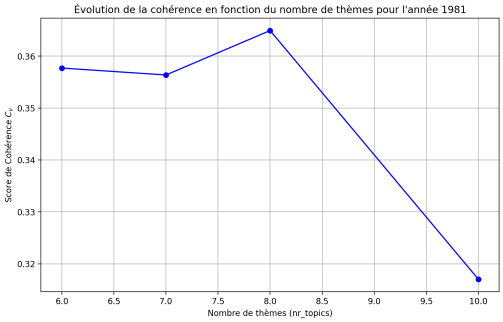

FIGURE 3 – Évolution du score de cohérence en fonction du nombre de topics (1981)

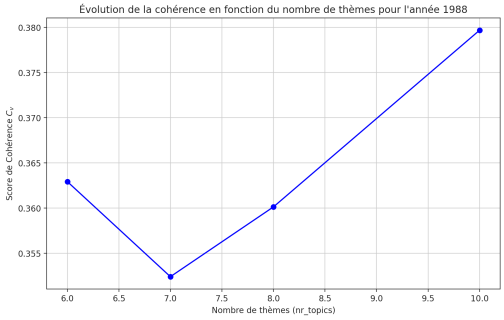

FIGURE 4 – Évolution du score de cohérence en fonction du nombre de topics (1988)

Cependant, afin de garantir la lisibilité de notre cartographie, nous n'avons gardé que les partis ayant au moins 30 manifestes de candidats et nous n'affichons que 20 candidats par parti. Nous sélectionnons les candidats possédant les scores thématiques les plus élevés pour chaque thème identifié, favorisant ainsi l'apparition de clusters partisans cohérents. Cela représente 20 partis pour les élections de 1981 et 19 partis pour les élections de 1988.

5 Résultats

À partir des mots qui composent les thèmes trouvés par le modèle BERTopic, nous en déduisons les thèmes principaux des manifestes des élections législatives de 1981 et 1988.

5.1 Élections de 1981

Les thèmes dominants identifiés sont :

- **Thème 0 :** Union, politique et victoire électorale : ce thème partagé par pratiquement tous les partis, reflète le contexte global de mobilisation électorale de 1981, caractérisé par la perspective d'une alternance à gauche et la centralité d'un discours fondé sur l'union. Le graphique de distribution confirme que le thème T0 est presque universel, regroupant la majeure partie des candidats du PCF, du PS, du RPR et de la plupart des petits partis.
- **Thème 1 :** Gouvernement et pays : un second thème transversal centré sur la gouvernance et les priorités nationales, avec une présence significative tant dans les partis de gauche que de droite. Il reflète un discours plus programmatique, orienté vers le contenu des politiques publiques plutôt que vers la mobilisation électorale.
- **Thème 2 :** Travailleurs et revendications salariales : un thème minoritaire concentré chez les candidats de la gauche radicale, particulièrement Lutte ouvrière, évoquant la lutte des classes et la représentation des travailleurs.
- **Thème 3 :** Rassemblement populaire et éducation : un thème associé aux traditions gaullistes et centristes de rassemblement populaire, avec une certaine présence de thématiques liées à l'enseignement. Il est partagé par plusieurs partis de droite.
- **Thème 4 :** Énergie nucléaire et écologie : un thème de niche reflétant le mouvement écologiste émergent, regroupant les candidats des partis écologistes aux côtés de quelques candidats de la formation libérale-écologiste et du Parti socialiste unifié.
- **Thème 5 :** Écologie, société et avenir : un thème écologiste et sociétal plus large, très similaire au thème T4 mais qui s'étend vers des préoccupations sociales et programmatiques (avenir). La distribution montre qu'il capte des candidats issus d'un spectre de partis plus large que le thème T4, principalement antinucléaire.

— **Thème 6 :** Liberté, programme et société : un thème libéral-centriste mettant l'accent sur la liberté individuelle et la clarté du programme. Il est particulièrement présent chez les Républicains indépendants et les formations centristes.

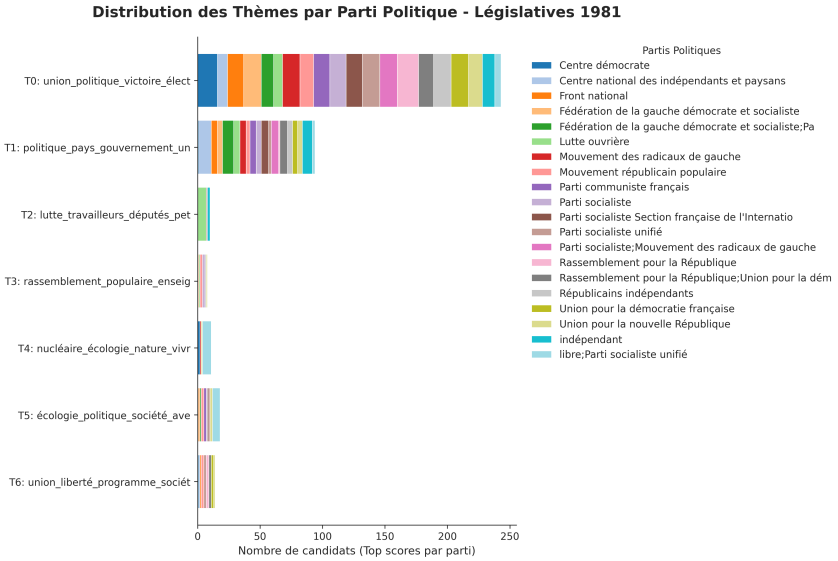

FIGURE 5 – Nombre de candidats qui évoquent chaque thème en fonction de leur classe politique pour l'année 1981

Ce graphique nous permet de voir quels sont les partis qui évoquent le plus les différents thèmes trouvés, comme mentionné dans l'analyse des thèmes.

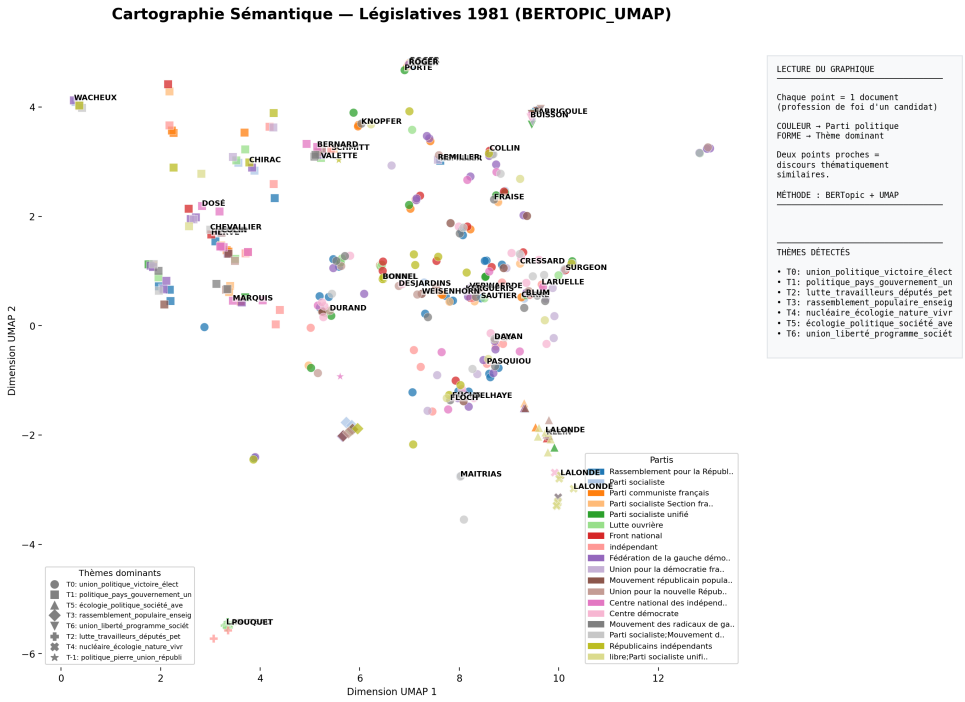

FIGURE 6 – Carte sémantique pour l'année 1981

Cette carte permet de connaître le positionnement de certains candidats de chaque parti par rapport aux principaux sujets abordés. Plus deux formes géométriques sont proches, plus leurs points de vue idéologiques sur le thème sont proches. Inversement, deux points éloignés signifient deux points de vue opposés. La partie droite de la carte regroupe les candidats utilisant des vocabulaires plus écologistes et libéraux-programmatiques (LALONDE et les candidats écologistes apparaissent aux coordonnées $(10, -2)$ et en dessous), tandis que la partie supérieure accueille les candidats aux discours plus singuliers (ROGER, PORTE en haut). La partie gauche du nuage est dominée par des marqueurs carrés (Thème T1 — gouvernement/pays), associés principalement aux partis de droite. L'isolement spatial des candidats de Lutte ouvrière (Thème T2 — travailleurs) confirme la distance lexicale entre le discours radical sur le travail et le vocabulaire politique dominant.

5.2 Élections de 1988

Nous effectuons la même analyse pour les élections de 1988. Les thèmes dominants identifiés sont :

- **Thème 0 :** Droite, politique et rassemblement : il s'agit du thème dominant, capturant environ 190 candidats et s'étendant à pratiquement tous les partis. Le graphique de distribution montre que le thème T0 est si prévalent qu'il rend tous les autres thèmes marginaux. Les mots-clés suggèrent que le discours électoral de 1988 est structuré autour d'une opposition gauche-droite.
- **Thème 1 :** Force, avenir et conviction populaire : c'est un thème de mobilisation tourné vers l'avenir, présent principalement chez les candidats du Front national, du Mouvement républicain populaire et de certains candidats du Parti socialiste (Section française de l'Internationale ouvrière).
- **Thème 2 :** Droite, politique et forces (dimanche) : une variante du thème T1, légèrement différenciée par la présence de « dimanche », reflétant possiblement des thèmes conservateurs religieux. Ce thème est partagé entre les différents partis de droite.
- **Thème 3 :** Unité, gouvernement Rocard et solidarité : un thème spécifiquement socialiste ancré dans le discours gouvernemental du futur cabinet de Michel Rocard. La distribution confirme que ce sujet est concentré parmi le PS et les candidats alliés (Mouvement des Radicaux de Gauche).
- **Thème 4 :** Force, avenir et vif appel populaire : une autre variante du discours de mobilisation de droite, mettant l'accent sur une énergie populaire vive (« vive »). Ce thème est présent au sein des formations RPR-UDF.
- **Thème 5 :** Avenir, force et confiance des électeurs : ce thème est un appel à la confiance des électeurs avec un lexique tourné vers l'avenir, partagé entre les candidats de gauche et les candidats centristes.
- **Thème 6 :** Union, député et centre local : thème fortement localisé, associé à des candidatures locales notables utilisant le vocabulaire des députés, des élus locaux (adjoints) et des réseaux centristes.
- **Thème 7 :** Droite, pouvez, politique, pays : un discours d'adresse directe (« vous pouvez ») déployé par les candidats de droite.
- **Thème 8 :** Augmentations salariales, députés et législation : un thème spécifiquement associé au PCF, capturant exclusivement les candidats communistes avec un vocabulaire focalisé sur les revendications salariales, la représentation parlementaire et l'action législative. Il n'apparaît que marginalement dans la distribution, reflétant le déclin de l'influence électorale du PCF en 1988.

Nous remarquons un changement dans les thèmes abordés par les candidats : les thèmes liés à l'écologie ont disparu par exemple et les thèmes semblent moins transverses que ceux de 1981.

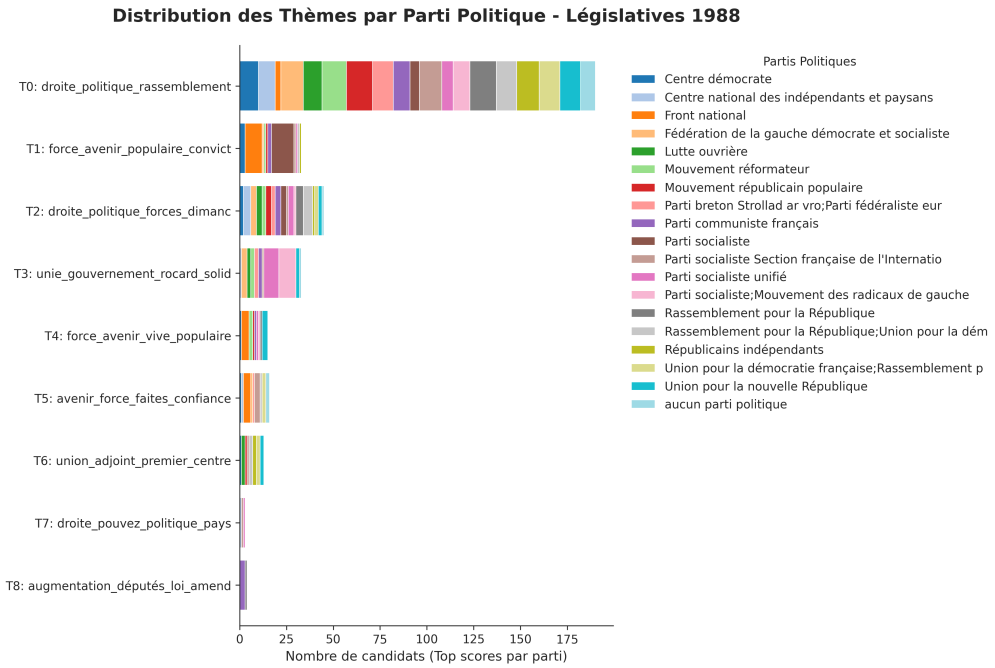

FIGURE 7 – Nombre de candidats qui évoquent chaque thème en fonction de leur classe politique pour l'année 1988

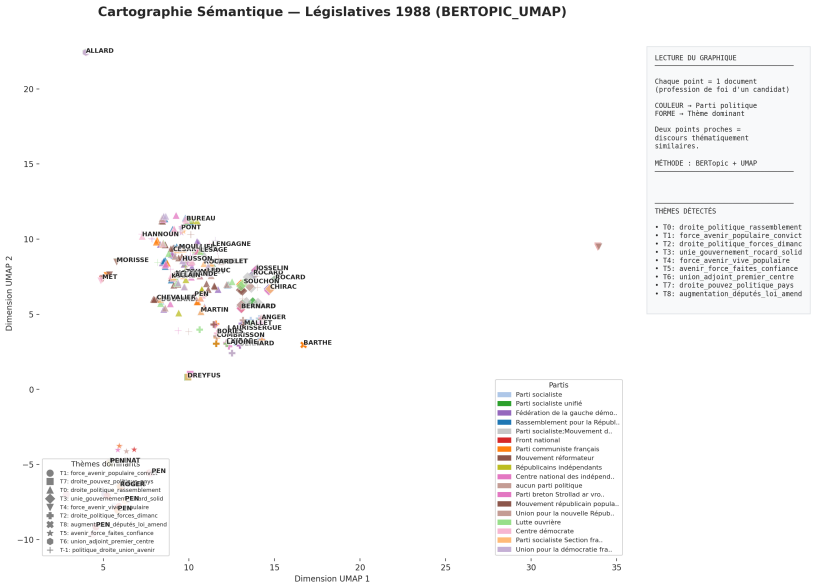

FIGURE 8 – Carte sémantique pour l'année 1988

De plus, la carte sémantique de 1988 (Figure 8) présente une organisation plus concentrée que celle de 1981. Le nuage principal regroupe la majorité des candidats dans une région centrale (coordonnées UMAP d'environ 5–20 sur la dimension 1 et 5–15 sur la dimension 2), avec un chevauchement partiel des discours des partis de gouvernement et de l'opposition, signe d'une convergence vers un vocabulaire institutionnel partagé. Le PCF, dont le thème T8 est associé à un discours sur les salaires et la législation, se situe dans un groupe en bas à gauche, nettement séparé du nuage principal, ce qui reflète son isolement politique croissant après la rupture de l'union de la gauche. Le point atypique ALLARD, aux coordonnées approximatives (5, 22), correspond à une profession de foi

dont le contenu diverge fortement du reste du corpus. Plusieurs candidats étiquetés Front national apparaissent dans un sous-groupe inférieur autour de (7, 8) (derrière la légende), confirmant la spécificité spatiale du Front national sur la carte sémantique.

5.3 Comparaison entre les élections

Plusieurs évolutions notables ressortent de la comparaison des deux cartes et des distributions thématiques :

- **Une forte concentration thématique :** On passe d'un paysage équilibré en 1981 (aucun thème ne dépassant 250 candidats) à une hégémonie lexicale en 1988. Le thème T0 sature alors l'espace discursif, signalant une polarisation du vocabulaire autour du triptyque « droite-gauche-rassemblement ».
- **Une recomposition des priorités :** La diversité de 1981, marquée par l'émergence de l'écologie (T4, T5) et des thématiques liées au travail (T2), s'efface en 1988. L'écologie disparaît de la structure principale, tandis que le discours de gauche abandonne ses grandes ambitions programmatiques d'opposition pour adopter un registre de gestion et de bilan.
- **La convergence du « centre » gouvernemental :** On observe en 1988 un chevauchement sémantique accru entre le PS, le RPR et l'UDF. Cette homogénéisation lexicale entre les partis de pouvoir témoigne d'une forme de convergence social-libérale.
- **L'isolement discursif du PCF :** Entre les deux scrutins, le Parti communiste subit une marginalisation spatiale et thématique nette. Relégué à des thèmes de niche (T8, T7) centrés sur des revendications catégorielles (salaires, amendements), il se détache du reste du spectre politique suite à la fin de l'Union de la gauche et à l'hégémonie du Parti socialiste.

6 Discussion

6.1 Validité de l'approche

L'utilisation de BERTopic et de UMAP produit des cartes dont la structure est cohérente avec les faits historiques. Les principales familles politiques sont plus ou moins séparées dans l'espace de projection (en particulier pour 1981, cela est moins apparent pour 1988), et les thèmes identifiés correspondent bien à ceux effectivement évoqués. Les scores de cohérence, assez faibles cependant (allant de 0,35 à 0,38), sont conformes aux valeurs pour des textes politiques courts issus d'un contenu OCR bruité.

Cependant, plusieurs limites doivent être reconnues :

- **Qualité de l'OCR :** La qualité variable de la transcription des manifestes (images) en textes entraîne du bruit dans les documents. Certains textes contiennent des artefacts (chiffres isolés, caractères spéciaux) qui biaisent les plongements (embeddings).
- **Problèmes liés à l'utilisation d'UMAP :** UMAP est une méthode stochastique dont les projections ne sont pas strictement comparables d'une année sur l'autre. Nos deux cartes ne peuvent donc pas être superposées pour mesurer les déplacements de position des partis.
- **Dominance du thème T0 en 1988 :** La forte dominance du thème T0 en 1988 peut refléter partiellement une limite de la procédure de fusion hiérarchique ; réduire l'ensemble initial à seulement 9 thèmes peut générer un sujet résiduel très large absorbant des discours hétérogènes.

7 Conclusion

Cette étude démontre la faisabilité et la pertinence d'une approche computationnelle pour l'analyse du discours électoral à grande échelle. Le pipeline BERTopic + UMAP appliqué aux manifestes des élections législatives de 1981 et 1988 révèle des structures thématiques cohérentes avec l'histoire politique de la période et identifie des évolutions discursives significatives entre les deux scrutins.

Les principaux résultats sont les suivants :

- Une concentration thématique en 1988 par rapport à 1981, où un seul sujet dominant absorbe la majorité des candidats. Ce qui reflète un usage du vocabulaire politique autour d'un axe d'opposition gauche-droite.
- Une recomposition thématique entre 1981 et 1988, passant d'un registre diversifié incluant des thèmes sur l'écologie, le travail et la liberté à un registre institutionnel plus homogène.
- Une convergence partielle des discours des partis de gouvernement en 1988.
- Une marginalisation des discours du PCF, visible par son isolement spatial et son confinement à un thème centré sur les revendications salariales et l'action législative.